

Covid-19 infección en Ecuador. Modelos matemáticos y predicciones

Una comparación de modelos, lineal, polinómico, logísticos y exponenciales aplicados a la infección por el virus Covid-19

Se realiza un análisis matemático simple del crecimiento de la infección en Python y dos modelos para comprender mejor la evolución de la infección.

Se crean modelos de series temporales del número total de personas infectadas hasta la fecha (es decir, las personas realmente infectadas más las personas que han sido infectadas). Estos modelos tienen parámetros, que se estimarán por ajuste de curva.

In [1]:

```
# Importar las librerías para el análisis
import pandas as pd
import numpy as np
from datetime import datetime, timedelta
from sklearn.metrics import mean_squared_error
from scipy.optimize import curve_fit
from scipy.optimize import fsolve
from sklearn import linear_model
import matplotlib.pyplot as plt
%matplotlib inline
```

In [2]:

```
# Actualizar los datos (URL)
```

```
url = 'http://cowid.netlify.com/data/full_data.csv'
```

```
df = pd.read_csv(url)  
df
```

Out[2]:

| | date | location | new_cases | new_deaths | total_cases | total_deaths |
|------|------------|-------------|-----------|------------|-------------|--------------|
| 0 | 2020-02-25 | Afghanistan | NaN | NaN | 1 | NaN |
| 1 | 2020-02-26 | Afghanistan | 0.0 | NaN | 1 | NaN |
| 2 | 2020-02-27 | Afghanistan | 0.0 | NaN | 1 | NaN |
| 3 | 2020-02-28 | Afghanistan | 0.0 | NaN | 1 | NaN |
| 4 | 2020-02-29 | Afghanistan | 0.0 | NaN | 1 | NaN |
| ... | ... | ... | ... | ... | ... | ... |
| 2862 | 2020-03-13 | World | 7488.0 | 338.0 | 132758 | 4956.0 |
| 2863 | 2020-03-14 | World | 9761.0 | 433.0 | 142534 | 5392.0 |
| 2864 | 2020-03-15 | World | 10967.0 | 343.0 | 153517 | 5735.0 |
| 2865 | 2020-03-16 | World | 13971.0 | 855.0 | 167506 | 6606.0 |
| 2866 | 2020-03-17 | World | 11594.0 | 819.0 | 179112 | 7426.0 |

2867 rows × 6 columns

Imprimos los resultados y agregamos el numero del dia

In [3]:

```
df = df[df['location'].isin(['Ecuador'])] #Filtro la Informacion solo para Ecuador
df = df.loc[:,['date','total_cases']] #Selecciono las columnas de analisis
# Expresar las fechas en numero de dias desde el 01 Enero
FMT = '%Y-%m-%d'
date = df['date']
df['date'] = date.map(lambda x : (datetime.strptime(x, FMT) - datetime.strptime("2020-01-01", FMT)).days)

df
```

Out[3]:

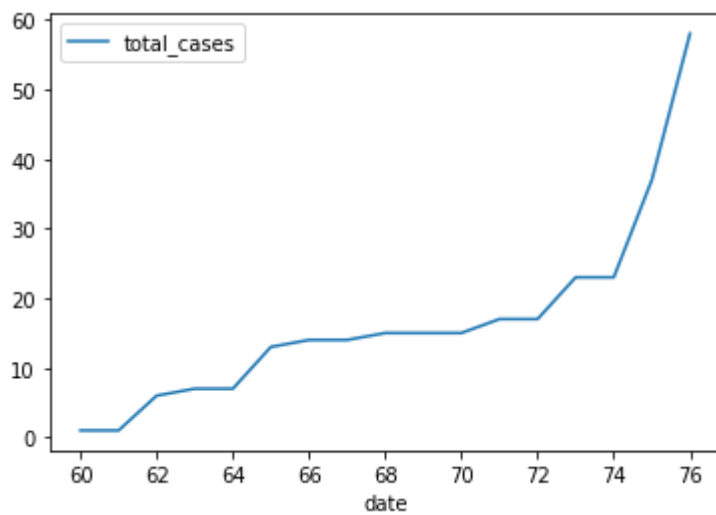
| | date | total_cases |
|-----|------|-------------|
| 681 | 60 | 1 |
| 682 | 61 | 1 |
| 683 | 62 | 6 |
| 684 | 63 | 7 |
| 685 | 64 | 7 |
| 686 | 65 | 13 |
| 687 | 66 | 14 |
| 688 | 67 | 14 |
| 689 | 68 | 15 |
| 690 | 69 | 15 |
| 691 | 70 | 15 |
| 692 | 71 | 17 |
| 693 | 72 | 17 |
| 694 | 73 | 23 |
| 695 | 74 | 23 |
| 696 | 75 | 37 |
| 697 | 76 | 58 |

In [4]:

```
df.plot(x='date', y='total_cases')
```

Out[4]:

<matplotlib.axes._subplots.AxesSubplot at 0x14dabe3b0d0>



Ahora podemos analizar los cuatro modelos que tomaré en el examen, que son la función lineal, polinómica, logística y la función exponencial. Cada modelo tiene tres parámetros, que se estimarán mediante un cálculo de ajuste de curva en los datos históricos.

EL modelo lineal


La regresión lineal es un algoritmo de aprendizaje supervisado que se utiliza en Machine Learning y en estadística. En su versión más sencilla, lo que haremos es «dibujar una recta» que nos indicará la tendencia de un conjunto de datos continuos.

Recordemos rápidamente la fórmula de la recta:

$$Y = mX + b$$

Donde Y es el resultado, X es la variable, m la pendiente (o coeficiente) de la recta y b la constante o también conocida como el «punto de corte con el eje Y» en la gráfica (cuando $X=0$) Ejemplo

The development in Pizza prices in Denmark from 2009 to 2018



Recordemos que los algoritmos de Machine Learning Supervisados, aprenden por sí mismos y -en este caso- a obtener automáticamente esa «recta» que buscamos con la tendencia de predicción. Para hacerlo se mide el error con respecto a los puntos de entrada y el valor «Y» de salida real.

In [8]:

```
x = list(df.iloc[:, 0]) # Fecha
y = list(df.iloc[:, 1]) # Numero de casos
# Creamos el objeto de Regresión Lineal
regr = linear_model.LinearRegression()

# Entrenamos nuestro modelo
regr.fit(np.array(x).reshape(-1, 1), y)

# Veamos los coeficientes obtenidos, En nuestro caso, serán la Tangente
print('Coefficients: \n', regr.coef_)
# Este es el valor donde corta el eje Y (en X=0)
print('Independent term: \n', regr.intercept_)
# Error Cuadrado Medio
```

```
Coefficients:
[2.31617647]
Independent term:
-140.85294117647058
```

De la ecuación de la recta $y = mX + b$ nuestra pendiente «m» es el coeficiente y el término independiente «b»

In [9]:


```
#Vamos a comprobar:
# Quiero predecir cuántos "Casos" voy a obtener por en el día 100,
# según nuestro modelo, hacemos:
y_prediccion = regr.predict([[100]])
print(int(y_prediccion))
```

90

In [10]:

```
#Graficar
plt.scatter(x, y)
x_real = np.array(range(50, 100))
print(x_real)
plt.plot(x_real, regr.predict(x_real.reshape(-1, 1)), color='green')
plt.show()
```

```
[50 51 52 53 54 55 56 57 58 59 60 61 62 63 64 65 66 67 68 69 70 71 72 73
 74 75 76 77 78 79 80 81 82 83 84 85 86 87 88 89 90 91 92 93 94 95 96 97
 98 99]
```



Analisis covid Ecuador


In [11]:

```
# Actualizar los datos (URL)
#datos tomados
url = 'ecuador-covid-data.csv'
df = pd.read_csv(url)
df = df.fillna(0)
df
```

Out[11]:

| | iso_code | continent | location | date | total_cases | new_cases | new_cases_smoothed | tot |
|-----|----------|---------------|----------|------------|-------------|-----------|--------------------|-----|
| 0 | ECU | South America | Ecuador | 2019-12-31 | 0.0 | 0.0 | 0.000 | |
| 1 | ECU | South America | Ecuador | 2020-01-01 | 0.0 | 0.0 | 0.000 | |
| 2 | ECU | South America | Ecuador | 2020-01-02 | 0.0 | 0.0 | 0.000 | |
| 3 | ECU | South America | Ecuador | 2020-01-03 | 0.0 | 0.0 | 0.000 | |
| 4 | ECU | South America | Ecuador | 2020-01-04 | 0.0 | 0.0 | 0.000 | |
| ... | ... | ... | ... | ... | ... | ... | ... | |
| 303 | ECU | South America | Ecuador | 2020-10-29 | 164908.0 | 1716.0 | 1326.143 | |
| 304 | ECU | South America | Ecuador | 2020-10-30 | 166302.0 | 1394.0 | 1407.286 | |
| 305 | ECU | South America | Ecuador | 2020-10-31 | 167147.0 | 845.0 | 1268.143 | |
| 306 | ECU | South America | Ecuador | 2020-11-01 | 168192.0 | 1045.0 | 1225.429 | |
| 307 | ECU | South America | Ecuador | 2020-11-02 | 169194.0 | 1002.0 | 1079.857 | |

308 rows × 50 columns



In [60]:

```
#Vamos a comprobar:
# Quiero predecir cuántos "Casos" voy a obtener por en el día 322,
# según nuestro modelo, hacemos:
y_prediccion = regr.predict([[322]])
print("Despues de 7 días")
print(int(y_prediccion))
```

Despues de 7 días

604

In [61]:

```
#Vamos a comprobar:  
# Quiero predecir cuántos "Casos" voy a obtener por en el día 352,  
# según nuestro modelo, hacemos:  
y_prediccion = regr.predict([[352]])  
print("Despues de 30 días")  
print(int(y_prediccion))
```

Despues de 30 días

674


In [25]:

```
# Implementar Covid-19 Regresión Lineal  
import numpy as np  
import matplotlib.pyplot as plt  
from sklearn.linear_model import LinearRegression #Regresión Lineal con scikit-learn  
import pandas as pd  
from datetime import datetime, timedelta  
import matplotlib.pyplot as plt  
%matplotlib inline
```

In [31]:

```
def f(x): # función  $f(x) = 0.1*x + 1.25 + 0.2*\text{Ruido\_Gaussiano}$ 
    np.random.seed(42) # para poder reproducirlo
    y = 0.1*x + 1.25 + 0.2*np.random.randn(x.shape[0])
    return y

df = pd.read_csv('ecuador-covid-data.csv').fillna(0) # poniendo datos nan a cero
ndf1=ndf[['date', 'total_cases', 'total_deaths']]
x=np.arange(1, len(ndf1)+1, 1) # arreglo de x lo creo para simular el numero del dia y el
# numero de casos
y=np.array(ndf1.values[:,1])
y1=np.array(ndf1.values[:,2])
# hacemos un gráfico de los datos que hemos generado
plt.figure(figsize=(20, 20))
plt.scatter(x,y,label='N. Infectados')
plt.scatter(x,y1,label='N. Muertes')
plt.grid(True)
plt.legend()
plt.title('Infectados');
```



In [32]:


```
regresion_lineal = LinearRegression() # creamos una instancia de LinearRegression
# instruimos a la regresión lineal que aprenda de los datos (x,y)
regresion_lineal.fit(x.reshape(-1,1), y)
# vemos los parámetros que ha estimado la regresión lineal
print('w = ' + str(regresion_lineal.coef_[0]) + ', b = ' + str(regresion_lineal.intercept_))
# resultado: w = [0.09183522], b = 1.2858792525736682
if (regresion_lineal.intercept_ < 0):
    ecua='y = {}x {}'
else:
    ecua='y = {}x + {}'
print(ecua.format(regresion_lineal.coef_[0],regresion_lineal.intercept_))
```

w = 728.4140897638947, b = -19622.134220362786

y = 728.4140897638947x -19622.134220362786

In [36]:

```
fun= lambda num: regresion_lineal.coef_[0]*num+regresion_lineal.intercept_  
plt.figure(figsize=(20, 20))  
plt.scatter(x,y,label='Real')  
plt.grid(True)  
plt.title('Regresión Lineal Infectados Covid-19');  
x1=np.arange(1,len(ndf1)+51,1)  
plt.scatter(x1,fun(x1),linewidth=5.0,label='Prediccion')  
plt.legend()  
plt.show()
```



In [37]:

```

regresion_lineal = LinearRegression() # creamos una instancia de LinearRegression
# instruimos a la regresión lineal que aprenda de los datos (x,y)
regresion_lineal.fit(x.reshape(-1,1), y1)
# vemos los parámetros que ha estimado la regresión lineal
print('w = ' + str(regresion_lineal.coef_[0]) + ', b = ' + str(regresion_lineal.intercept_))
print(ecua.format(regresion_lineal.coef_[0], regresion_lineal.intercept_))

```

w = 57.77491796289733, b = -1815.1029457151653


y = 57.77491796289733x -1815.1029457151653

In [46]:

```

fun= lambda num: regresion_lineal.coef_[0]*num+regresion_lineal.intercept_
plt.figure(figsize=(15, 15))
plt.scatter(x,y1,label='Muertes')
plt.grid(True)
plt.title('Total Muertes por Covid-19');
x2 = np.arange(1,len(ndf1)+51,1)
plt.plot(x2,fun(x2),linewidth=5.0,label='Prediccion', color="orange")
plt.legend()
plt.show()

```



In []: